

Redes *Bayesianas*: o que são, para que servem, algoritmos e exemplos de aplicações.



Inteligência Artificial

Profa.: Inês Dutra

Roberto Ligeiro




Resumo

- Introdução.
- Raciocinando sobre incertezas.
- Cálculo de Probabilidades.
- Aplicando a regra de *bayes*.
- Redes *Bayesianas*.
- Inferência em redes *bayesianas*.
- Aplicações.
- Considerações finais.
- Referências.



Introdução

- Sistemas que agem racionalmente
 - Raciocínio Lógico
 - Raciocínio Probabilístico
 - Situações onde não se conhece todo o escopo do problema.
 - Redes *Bayesianas* (início da década de 90)
 - Teoria de probabilidades
 - Teoria de Grafos



Raciocinando sobre incertezas

- “A principal vantagem de raciocínio probabilístico sobre raciocínio lógico é fato de que agentes podem tomar decisões racionais mesmo quando não existe informação suficiente para se provar que uma ação funcionará”[Russel]
- Alguns fatores podem condicionar a falta de informação em uma base de conhecimento:
 - Ignorância Teórica
 - Impossibilidade



Raciocinando sobre incertezas


- Utilizar conectivos que manipulem níveis de certeza e não apenas valores booleanos.
 - *"Eu tenho probabilidade 0.8 fazer um bom trabalho de IA".*
 - *"A probabilidade de um trabalho de IA ser bom é 0.7".*
 - *"A probabilidade de um bom trabalho de IA tirar A é 0.9".*
 - *"Quais são as minhas chances tirar A?"*
- Grafos podem representar relações causais entre eventos.



Raciocinando sobre incertezas

- Considere o domínio: *"Pela manhã meu carro não irá funcionar. Eu posso ouvir a ignição, mas nada acontece. Podem existir várias razões para o problema. O rádio funciona, então a bateria está boa. A causa mais provável é que a gasolina tenha sido roubada durante a noite ou que a mangueira esteja entupida. Também pode ser que seja o carburador sujo, um vazamento na ignição ou algo mais sério. Para descobrir primeiro eu verifico o medidor de gasolina. Ele indica 1/2 tanque, então eu decido limpar a mangueira da gasolina"*.
- Estados:
 - Funcionando?{sim,não}
 - Mangueira Limpa?{sim,não}
 - Gasolina?{sim,não}
 - Medidor{vazio, 1/2 ,cheio}

Raciocinando sobre incertezas



Função RP-Agente(percepção) **retorna** ação

{

Estático: conjunto de sentenças probabilísticas a respeito do problema.

Calcula novas probabilidades para o estado atual baseado na evidência disponível incluindo a percepção atual e a ação anterior.

Calcula as probabilidades para as possíveis ações, dado a descrição das ações e as probabilidades atuais.

Seleciona a ação com a maior expectativa.

Retorna ação.

}



Cálculo de Probabilidades

■ Probabilidade incondicional

- A probabilidade $P(a)$ de um evento a é um número dentro do intervalo $[0,1]$.
 - $P(a) = 1$ sss a é certo.
 - Se a e b são mutuamente exclusivos, então: $P(a \vee b) = P(a) + P(b)$.

■ Probabilidade condicional

- Probabilidade condicional $P(a/b) = x$, pode ser interpretada como: *"Dado o evento b , a probabilidade do evento a é x "*.
 - $P(b/a) = P(a/b)P(b)/P(a)$ - Regra de Bayes.

■ Tabela de Conjunção de probabilidades

- $P(A/B)=P(A,B)/P(B)$
- Tabela $n \times m$, representada pela probabilidade de cada configuração (a_i, b_i)
- Representam todo o domínio
- Para valores booleanos teríamos 2^n entradas

Cálculo de Probabilidades

- Tabela de Conjunção de probabilidades

- $P(X) = (a_1, \dots, a_n); \quad a_i \geq 0; \quad \sum a_i = 1$, onde a_i é a probabilidade de X estar no estado a_i , $P(X=a_i)$.

	b_1	b_2	b_3
a_1	0.4	0.3	0.6
a_2	0.6	0.7	0.4


Tabela1. $P(X|Y)$

- Se $P(Y) = \langle 0.4, 0.4, 0.2 \rangle$, aplicando $P(A/B) = P(A, B) / P(B)$

	b_1	b_2	b_3
a_1	0.16	0.12	0.12
a_2	0.24	0.28	0.08

Tabela2. $P(X, Y)$

- Com esta tabela pode-se ainda calcular $P(X)$ e $P(Y/X)$



Aplicando a Regra de *Bayes*

- Diagnóstico médico:


- *"um médico sabe que a meningite causa torcicolo em 50% dos casos. Porém, o médico também conhece algumas probabilidades incondicionais que dizem que, um caso de meningite atinge 1/50000 pessoas e, a probabilidade de alguém ter torcicolo é de 1/20."*

- Aplicando a rede de *Bayes*:

- $P(M/T) = (P(T|M)P(M))/P(T) = (0.5 \times 1/50000)/(1/20) = 0.0002$

- Por que não calcular estatisticamente $P(M/T)$?

- Surto de meningite => $P(M)$ aumenta. $P(M/T)$?



Redes Bayesianas

- Uma Rede *Bayesiana* consiste do seguinte:
 - Um conjunto de variáveis e um conjunto de arcos ligando as variáveis.
 - Cada variável possui um conjunto limitado de estados mutuamente exclusivos.
 - As variáveis e arcos formam um grafo dirigido sem ciclos (*DAG*).
 - Para cada variável A que possui como pais $B_1, \dots, B_n$, existe uma tabela $P(A / B_1, \dots, B_n)$.



Redes Bayesianas

- Exemplo

- *“Você possui um novo alarme contra ladrões em casa. Este alarme é muito confiável na detecção de ladrões, entretanto, ele também pode disparar caso ocorra um terremoto. Você tem dois vizinhos, João e Maria, os quais prometeram telefonar-lhe no trabalho caso o alarme dispare. João sempre liga quando ouve o alarme, entretanto, algumas vezes confunde o alarme com o telefone e também liga nestes casos. Maria, por outro lado, gosta de ouvir música alta e às vezes não escuta o alarme.”*

- Estados:

- Ladrão
 - Terremoto
 - Alarme
 - João
 - Maria



Redes Bayesianas



- Se conhecemos a probabilidade da ocorrência de um ladrão e de um terremoto, e ainda, a probabilidade de João e Maria telefonarem.
- Podemos Calcular $P(\text{Alarme}|\text{Ladrão}, \text{Terremoto})$:

Ladrão	Terremoto	$P(\text{Alarme} \text{Ladrão}, \text{Terremoto})$	
		Verdadeiro	Falso
Verdadeiro	Verdadeiro	0.95	0.050
Verdadeiro	Falso	0.95	0.050
Falso	Verdadeiro	0.29	0.71
Falso	Falso	0.001	0.999


Redes Bayesianas

- Podemos construir a seguinte rede:

L	P(L)
V	.001




T	P(T)
V	.002





L	T	P(A)
V	V	.95
V	F	.95
F	V	.29
F	F	.001

J	P(J)
V	.90
F	.05



M	P(M)
V	.70
F	.01






Redes Bayesianas

- Considere que se deseja calcular a probabilidade do alarme ter tocado, mas, nem um ladrão nem um terremoto aconteceram, e ambos, João e Maria ligaram, ou $P(J \wedge M \wedge A \wedge \neg L \wedge \neg T)$.

- $P(J \wedge M \wedge A \wedge \neg L \wedge \neg T) = P(J|A)P(M|A)P(A|\neg L \wedge \neg T)P(\neg L)P(\neg T)$
- $= 0.9 \times 0.7 \times 0.001 \times 0.999 \times 0.998 = 0.00062$





Redes Bayesianas

- Método para construção de redes *bayesianas*:
 - Escolha um conjunto de variáveis X_i que descrevam o domínio.
 - Escolha uma ordem para as variáveis.
 - Enquanto existir variáveis:
 - Escolha uma variável X_i e adicione um nó na rede.
 - Determine os nós $Pais(X_i)$ dentre os nós que já estejam na rede e que tenham influência direta em X_i .
 - Defina a tabela de probabilidades condicionais para X_i .

Redes Bayesianas

- Método para construção de redes *bayesianas*:
 - *MariaLig*: raiz.
 - *JoãoLig*: Se Maria ligou, então, provavelmente, o alarme tocou. Neste caso, *MariaLig* influencia *JoaoLig*. Portanto, *MariaLig* é pai de *JoaoLig*.
 - *Alarme*: Claramente, se ambos ligaram, provavelmente o alarme tocou. Portanto, *Alarme* é influenciado por *JoãoLig* e *MariaLig*.
 - *Ladrão*: Influenciado apenas por *Alarme*.
 - *Terremoto*: Se o alarme tocou, provavelmente, um terremoto pode ser acontecido. Entretanto, se existe um *Ladrão*, então as chances de um terremoto diminuem. Neste caso, *Terremoto* é influenciado por *Ladrão* e *Alarme*.





Redes Bayesianas

- Método para construção de redes *bayesianas*:
 - Compactação de nós
 - Se cada nó dependesse de todos os outros, teríamos uma tabela de probabilidade de 2^n entradas – para variáveis booleanas -(assim como tabela de conjunção de probabilidades).
 - Localidade estrutural
 - Padrão de relacionamento entre os nós.
 - Uma variável aleatória é influenciada por no máximo k outras (seu pais na rede).
 - Por isto: $P(MariaLig|JoaoLig,Alarme, Terremoto,Ladrão) = P(MariaLig|Alarme)$
 - Para uma rede com 20 nós:
 - $2^n = \sim 1\text{milão}$
 - Considerando $k = 5 \Rightarrow 640$




Inferência em redes *bayesianas*

- Independência condicional
 - Sabemos que um nó é independente de seus predecessores dado seu pai na rede.
 - Porém, para realização de inferências é necessário saber mais a respeito da relação entre os nós.
 - É necessário saber se um conjunto de nós X é independente de outro conjunto Y , dado que um conjunto de evidências E (X é *d-separated* de Y)
 - Se todo caminho não dirigido entre um nó em X e um nó em Y é *d-separated* por E , então X e Y são condicionalmente independentes dada a evidência E .

Inferência em redes *bayesianas*

- Independência condicional
 - Três possibilidades:






Inferência em redes *bayesianas*

- A tarefa básica de uma inferência probabilística é computar a distribuição de probabilidades posterior para um conjunto de *variáveis de consulta* (*query variables*) $\Rightarrow P(Query/Evidence)$.
- Para o exemplo anterior
 - *Ladrão* constitui uma boa variável de consulta.
 - *JoãoLig*, *MariaLig* seriam boas variáveis de evidência.

Inferência em redes *bayesianas*

■ Exemplo:



■ Dado que a grama está molhada, qual a probabilidade de ter chovido?

■ Dado que a grama está molhada, qual a probabilidade de o regador ter sido ligado?



Inferência em redes *bayesianas*

- Neste caso, S e R tornam-se dependentes dado que o nó W , a evidência, é filho de ambos, ou seja, não S e R não são d-separados. Assim, para o calculo de $P(S/W)$ deve-se considerar $P(R)$ e vice-versa. A equação seria ($1 = T$ e $0 = V$):

$$\begin{aligned} P(S=1/W=1) &= P(S=1, W=1)/P(W=1) \\ &= \sum_{c,r} (P(C=c_r, S=1, R=r_r, W=1)/P(W=1)) = 0.2781/0.6471 \end{aligned}$$

$$\begin{aligned} P(R=1/W=1) &= P(R=1, W=1)/P(W=1) \\ &= \sum_{c,s} (P(C=c_r, S=s_r, R=1, W=1)/P(W=1)) = 0.4581/0.6471 \end{aligned}$$

Onde ($W = 1$):

$$P(W=1) = \sum_{c,r,s} P(C=c_r, S=s_r, R=r_r, W=1) = 0.6471$$




Inferência em redes *bayesianas*

- Inferências podem ser realizadas sobre redes *Bayesianas* para:
 - Diagnósticos: Dos efeitos para as causas. Dado *JoaoLig*, $P(Ladrão|JoaoLig)$
 - Causas: De causas para efeitos. Dado *Ladrão*, $P(JoaoLig|Ladrão)$

Inferência em redes *bayesianas*


- Algoritmo para inferências
 - Pode ser *NP-Hard*, dependendo de como o problema foi modelado.
 - Para uma classe de redes possui sempre tempo linear: redes simplesmente conexas.






Inferência em redes *bayesianas*

- Estratégia geral:
 - 1. Expressar $P(X/E)$ em relação a E_x^- , E_x^+ .
 - 2. Computar a contribuição de E_x^+ através de seus efeitos em $\text{Pais}(X)$, e então transportar tais efeitos para X .
 - 3. Computar a contribuição de E_x^- através de seus efeitos em $\text{Filhos}(X)$, e então transportar tais efeitos para X . Note que computar os efeitos nos filhos de X é uma recursão do problema de computar os efeitos em X .
- Chamadas recursivas a partir de X por todos seus arcos.
 - Termina em nós de evidência, raízes e folhas da árvore.
 - Cada chamada recursiva exclui o nó que a chamou, desta forma, a árvore é coberta apenas uma vez.



Inferência em redes *bayesianas*

- Inferência em Redes *Bayesianas* Multiconectadas
 - *Clustering* – Transforma probabilisticamente (não topologicamente) a rede em uma rede simplesmente conexa.
 - *Conditioning* – Faz uma transformação na rede instanciando variáveis em valores definidos, e então, e então produz uma rede simplesmente conexa para cada variável instanciada.
 - *Stochastic simulation* – Usa a rede para gerar um grande número de modelos concretos de um domínio. A partir destes modelos o algoritmo calcula uma aproximação de uma inferência.



Aplicações

- *Pathfinder*, Heckerman 1990. Stanford – Sistema para diagnósticos de problemas nas glândulas linfáticas.
- *Map Learning*, Ken Basye 1990. Brown University – Este projeto combina problemas de diagnostico e teoria de decisão. Um robô deve percorrer um “labirinto”, procurando aprender os caminhos percorridos e, ao mesmo tempo, explorar caminhos desconhecidos.
- *AutoClass*, NASA’s Ames Research Center, 1998 - Sistema de exploração e aquisição de conhecimento espacial. Este projeto está desenvolvendo uma rede *bayesiana* que permita a interpolação automática de dados espaciais oriundos de diferentes observatórios e planetários espalhados pelo mundo.
- *Lumiere*, Microsoft Research, 1998 – O projeto pretende criar um sistema que possa automaticamente e inteligentemente interagir com outros sistemas, antecipando os objetivos e necessidades dos usuários.



Considerações Finais

- Redes *bayesianas* constituem uma forma natural para representação de informações condicionalmente independentes.
- Boa solução a problemas onde conclusões não podem ser obtidas apenas do domínio do problema.
- Inferências sobre redes *bayesianas*.
 - Podem ser executadas em tempo linear.
 - *NP-hard* para maioria dos casos.
 - Aplicação de técnicas.



Referências

- Charniak, Eugene. "Bayesians Networks without Tears". *IA Magazine*, 1991.
- Darwiche, Adan & Huang, Cecil. "Inference in Belief Networks: A procedural guide". *International Journal of Approximate Reasoning*, 1994.
- Jensen, V. Finn. "Bayesian Networks and Decision Graphs". Springer-Verlag, 2001.
- Murphyk, P. Kevin. "A Brief Introduction to Graphical Models and Bayesian Networks".
<http://www.cs.berkeley.edu/~murphyk/Bayes/bayes.html>
- Niedermayer, Daryle. "An Introduction to Bayesian Networks and their Contemporary Applications". 1998.
- Russel, J. Stuart & Norvig, Peter. "Artificial Intelligence: A modern Approach". Prentice Hall.